LiteLLM Gateway - Unified AI Platform cho VNPAY

> **Tài liệu nội bộ** | Ngày: 02/04/2026 | Người trình bày: DuHD - AI Platform Team
> **Đối tượng**: CTO, Tech Leaders, Engineering Managers

1. Vấn đề hiện tại

Các đội phát triển tại VNPAY đang sử dụng AI/LLM một cách phân tán:

- Mỗi developer tự quản lý API key riêng (Anthropic, OpenAI, Google...)
- Không kiểm soát được chi phí sử dụng AI trên toàn công ty
- Không có audit trail - ai dùng gì, bao nhiêu, cho mục đích gì
- Rủi ro bảo mật: API keys nằm rải rác trên máy cá nhân, Slack, .env files
- Không thể enforce policy: giới hạn model nào được dùng, budget bao nhiêu/tháng

2. Giải pháp: LiteLLM Gateway

LiteLLM là **Unified LLM Gateway** - một proxy trung tâm kết nối tất cả AI providers qua một endpoint duy nhất, chạy trên hạ tầng K8s nội bộ VNPayCloud.

```
     Consumers (gửi request)
     ========================
Claude Code      Antigravity      Hệ thống nội bộ
CLI / VSCode /   (AI Agent)       (Chatbot, QA,
Xcode                              Automation...)
     |               |               |
     +---------------+---------------+
                     |
                     v
          +--------------------+
          |  LiteLLM Gateway   |
          |  Guardrails        |
          |  Key Management    |
          |  Cost Tracking     |
          +--------------------+
                     |
     +-------+-------+-------+-------+-------+
     |       |       |       |       |       |
     v       v       v       v       v       v
 VNPAY    Anthropic OpenAI  Gemini DeepSeek Ollama
 GenAI    Claude    GPT-4o  Gemini  DeepSeek (On-premise)
 GLM-4    Opus/     o3-pro  2.5     R1       Qwen, Llama
 (v_glm46)Sonnet    Codex   Flash             CodeGemma...
     ========================
     Providers (LLM backends)
```

3. Kiến trúc triển khai tại VNPayCloud

```
                    Developer / Service
                          |
                          | HTTPS
                          v
                   VNPayCloud WAF/CDN
               (api-llm.x.vnshop.cloud)
                          |
                          v
                Floating IP: 103.67.184.237
                          |
                          v
+-----------------------------------------------------------------+
|                     VNPayCloud K8s Cluster                      |
|                     (sdlc-go-k8s-v2)                            |
|                                                                 |
|           LB VIP: 10.10.1.87 (SG: WAF IPs allowlist)           |
|                        |                                        |
|             NodePort 30080/30443                                |
|                        |                                        |
|             NGINX Ingress Controller                            |
|             ├── api-llm.x.vnshop.cloud  (public, WAF whitelist) |
|             └── litellm.x.vnshop.cloud  (admin, Teleport only)  |
|                        |                                        |
|  +--- Namespace: litellm -----------------------------------+   |
|  |                                                          |   |
|  |  +------------------+   +------------+   +---------+    |   |
|  |  | LiteLLM Gateway  |   | PostgreSQL |   |  Redis  |    |   |
|  |  | (2 replicas, HA) |   | 16-alpine  |   | Cache   |    |   |
|  |  | Port: 4000       |   | Keys, Teams|   | Rate    |    |   |
|  |  |                  |   | Usage Logs |   | Limit   |    |   |
|  |  | - Guardrails     |   +------------+   +---------+    |   |
|  |  | - Key Mgmt       |        5Gi PVC                     |   |
|  |  | - Cost Tracking  |                                    |   |
|  |  | - Model Router   |                                    |   |
|  |  +--------+---------+                                    |   |
|  |           |                                              |   |
|  +-----------|----------------------------------------------+   |
|              |                                                  |
|  +--- Namespace: sdlc-go-prod ---+  +--- Namespace: teleport -+ |
|  | GoClaw, Web Dashboard,       |  | Teleport Agent          | |
```

```
|  | Serena, GitNexus ...          |  | (SSO + MFA, admin UI)   | |
|  +-------------------------------+  +-------------------------+ |
|                                                                  |
+------------------------------------------------------------------+
       |                    |                        |
       v                    v                        v
   VNPAY GenAI         Anthropic API            Ollama Server
   genai.vnpay.vn      (Cloud)                  (On-premise)
   (GLM-4, on-premise)                          (Future)
```

Thành phần	Chi tiết
Hạ tầng	K8s cluster `sdlc-go-k8s-v2` trên VNPayCloud (3 worker nodes, 4vCPU/8GB each)
Namespace	`litellm` - tách biệt hoàn toàn khỏi workload khác
HA	2 replicas LiteLLM + PodDisruptionBudget, zero-downtime rolling upgrade
Database	PostgreSQL 16 riêng (lưu virtual keys, teams, usage logs, model config)
Cache	Redis (response cache, rate limiting, session state)
Public API	`api-llm.x.vnshop.cloud` → WAF/CDN → Floating IP `103.67.184.237` → LB → Ingress
Admin UI	`litellm.x.vnshop.cloud` → Teleport SSO + MFA (admin only)
WAF	VNPayCloud WAF/CDN (14 WAF IPs whitelist tại NGINX Ingress)
TLS	Wildcard cert `*.x.vnshop.cloud` (WAF terminate TLS, internal HTTP)
Bảo mật	WAF IP whitelist, LiteLLM API key auth, SealedSecrets cho provider credentials
Monitoring	Jaeger (request tracing), Grafana (cost dashboard), Prometheus metrics
Models hiện tại	`v_glm46` (VNPAY GenAI GLM-4 on-premise) — tested & verified

Truy cập hiện tại: Public endpoint `https://api-llm.x.vnshop.cloud` qua WAF/CDN. Developer chỉ cần API key, không cần VPN hay Teleport. Admin dashboard qua Teleport SSO tại `litellm.x.vnshop.cloud`.

4. Lợi ích Enterprise

Chi phí & Kiểm soát

- **Cost tracking real-time**: Dashboard hiển thị chi phí theo team, dự án, cá nhân
- **Budget limits**: Set ngân sách tối đa/tháng cho mỗi team (alert khi đạt 80%)
- **Rate limiting**: Giới hạn request/phút để tránh chi phí đột biến
- **Một hóa đơn**: Thay vì mỗi dev tự mua credits riêng

Bảo mật & Compliance

- **WAF/CDN**: Traffic qua VNPayCloud WAF trước khi tới gateway, chống DDoS và injection
- **API Key Auth**: Mọi request cần virtual key hợp lệ, key có rate limit và budget
- **Audit log**: Ghi nhận mọi request - ai, lúc nào, model nào, bao nhiêu tokens
- **Key rotation**: Thay đổi API key provider mà không ảnh hưởng người dùng (virtual key tách biệt khỏi provider key)
- **Data sovereignty**: Gateway chạy trên VNPayCloud, dữ liệu nhạy cảm route qua VNPAY GenAI on-premise (zero data egress)
- **Guardrails**: PII auto-redaction, prompt injection blocking, data leak prevention - filter tại gateway trước khi data rời infra
- **Admin UI bảo mật**: Dashboard quản trị chỉ truy cập qua Teleport SSO + MFA

On-premise Models: VNPAY GenAI & Ollama

LiteLLM hỗ trợ kết nối các LLM chạy trực tiếp trên hạ tầng nội bộ VNPAY, **dữ liệu không bao giờ rời khỏi datacenter**:

```
LiteLLM Gateway
     |
     +---> VNPAY GenAI: genai.vnpay.vn (GLM-4, đã triển khai)
     |
     +---> Cloud: Anthropic, OpenAI, Gemini (khi cần model mạnh)
     |
     +---> Ollama Server (future, mạng nội bộ VNPAY)
            GPU Server / VNPayCloud VM
            ├── qwen2.5-coder:32b    (coding, 32B params)
            ├── llama3.3:70b         (general, 70B params)
            ├── codegemma:7b         (code review, nhẹ)
            └── deepseek-r1:14b      (reasoning)
```

Cấu hình - thêm model qua `config.yaml` hoặc Dashboard UI:

```yaml
model_list:
  # VNPAY GenAI Gateway (on-premise, đã triển khai)
  - model_name: v_glm46
    litellm_params:
      model: openai/v_glm46
      api_base: https://genai.vnpay.vn/aigateway/llm_glm46/v1
      api_key: os.environ/VNPAY_GENAI_API_KEY

  # Ollama models (on-premise, future)
  - model_name: qwen-coder-local
    litellm_params:
      model: ollama/qwen2.5-coder:32b
      api_base: http://ollama-server.vnpay.internal:11434
```

So sánh Cloud vs On-premise:

	Cloud Models	On-premise (VNPAY GenAI / Ollama)
Chi phí	Pay-per-token	Hạ tầng sẵn có - chạy unlimited
Dữ liệu	Gửi ra internet (có Guardrails filter)	100% nội bộ - zero data egress
Latency	~500ms-2s (phụ thuộc provider)	~100-500ms (mạng nội bộ)
Compliance	Phụ thuộc DPA với provider	Hoàn toàn kiểm soát
Use case	Task phức tạp cần model mạnh	Code review, dịch thuật, phân tích log, dữ liệu nhạy cảm

Hybrid routing - LiteLLM tự động route theo policy:

- Dữ liệu nhạy cảm (tài chính, PII) -> route tới **VNPAY GenAI on-premise**
- Task cần model mạnh (kiến trúc, debug phức tạp) -> route tới **Claude/GPT-4o cloud**
- Task đơn giản (format code, tóm tắt) -> route tới **on-premise** (tiết kiệm chi phí)

AI Security Guardrails

LiteLLM tích hợp lớp bảo vệ **Guardrails** - kiểm soát nội dung đầu vào/đầu ra trước khi gửi tới LLM provider, đảm bảo an toàn dữ liệu doanh nghiệp:

```
Developer / App                      LLM Provider
     |                                    ^
     v                                    |
+-----------+    +----------------+    +--+--+
|  Request  |--->|  GUARDRAILS    |--->|  AI |
|           |    |                |    |Model|
|  Response |<---|  - PII Redact  |<---|     |
+-----------+    |  - Injection   |    +-----+
                 |  - Toxic Filter|
                 |  - Data Leak   |
                 |  - Custom Rule |
                 +----------------+
                 (chạy trên infra VNPAY)
```

Guardrail	Chức năng	Ví dụ
Prompt Injection Blocking	Phát hiện và chặn prompt injection attacks trong input	Chặn khi user cố gắng bypass system prompt, jailbreak model, hoặc inject lệnh độc hại qua input
PII Auto-Redaction	Tự động che/xóa thông tin cá nhân (CCCD, SĐT, STK, email) trước khi gửi ra ngoài	`"Khách hàng Nguyễn Văn A, SĐT 0901234567" ->` `"Khách hàng [REDACTED], SĐT [REDACTED]"` - dữ liệu nhạy cảm không bao giờ rời khỏi infra VNPAY
Toxic Response Filtering	Lọc nội dung độc hại, không phù hợp trong response từ LLM	Chặn output chứa nội dung bạo lực, phân biệt, hoặc không phù hợp với quy chuẩn doanh nghiệp
Data Leak Prevention	Ngăn rò rỉ dữ liệu nội bộ (API keys, credentials, schema DB, source code nhạy cảm)	Phát hiện và chặn khi prompt chứa connection strings, private keys, hoặc nội dung classified
Custom Policy Engine	Tạo rules riêng theo chính sách VNPAY	Ví dụ: chặn mọi request liên quan đến dữ liệu tài chính chưa public, giới hạn model nào được dùng cho dữ liệu nào, enforce tiếng Việt trong output

Điểm mấu chốt: Toàn bộ Guardrails xử lý **tại gateway trên VNPayCloud** - dữ liệu nhạy cảm được filter trước khi gửi tới Anthropic/OpenAI. Không phụ thuộc vào trust boundary của provider bên ngoài.

Cấu hình Guardrails qua `config.yaml` hoặc LiteLLM Dashboard, không cần thay đổi code phía client:

```yaml
# Ví dụ config guardrails
litellm_settings:
  guardrails:
    - prompt_injection:        # Chặn prompt injection
        callbacks: [lakera_prompt_injection]
        default_on: true
    - pii_masking:             # Che thông tin cá nhân
        callbacks: [presidio]
        default_on: true
    - content_moderation:      # Lọc nội dung độc hại
        callbacks: [openai_moderation]
        default_on: true
    - custom_vnpay_policy:     # Policy riêng VNPAY
        callbacks: [custom_guardrail]
        default_on: true
```

Supply Chain Security - Bài học từ sự cố 24/03/2026

> **Context**: Ngày 24/03/2026, hacker nhóm **TeamPCP** đã upload 2 phiên bản độc hại (v1.82.7, v1.82.8) lên PyPI thông qua token bị đánh cắp từ CI/CD pipeline. Payload thu thập API keys, SSH keys, K8s tokens, cloud credentials và gửi về server của attacker. Phiên bản độc hại tồn tại ~3 giờ trước khi bị gỡ. Deployment VNPAY dùng v1.82.3 - **KHÔNG bị ảnh hưởng**.

Các biện pháp đã áp dụng để hạn chế rủi ro:

Biện pháp	Chi tiết
Pin image digest	Image K8s pin theo SHA256 digest cụ thể, không dùng mutable tag (`main-latest` , `main-stable`)
Không dùng PyPI trực tiếp	Deploy qua Docker image (ghcr.io), không `pip install` runtime - tránh bị ảnh hưởng bởi PyPI compromise
IOC scan trước upgrade	Trước mỗi lần upgrade, kiểm tra: không có file `.pth` lạ, không có domain `models.litellm.cloud` / `checkmarx.zone`

Biện pháp	Chi tiết
Secrets isolation	Provider API keys nằm trong K8s SealedSecrets, developer chỉ nhận virtual key - nếu gateway bị compromise, key gốc không bị lộ
Network policy	LiteLLM pods chỉ được gọi ra Anthropic/OpenAI API endpoints, không gọi được domain lạ
Upgrade quy trình	Mọi upgrade phải qua review: check release notes -> verify image -> scan IOCs -> deploy staging -> deploy prod

Linh hoạt & Tối ưu

- **Multi-provider**: Chuyển đổi giữa VNPAY GenAI/Anthropic/OpenAI/Gemini không cần đổi code
- **Fallback tự động**: Model A lỗi -> tự động chuyển sang Model B
- **Load balancing**: Phân tải request qua nhiều API keys cùng provider
- **Model routing**: Dùng model on-premise cho task thường, model cloud cho task phức tạp

5. Hướng dẫn sử dụng

5.1 Claude Code CLI (Terminal)

Claude Code CLI là coding assistant chạy trực tiếp trong terminal - đọc/sửa code, chạy tests, tạo PR, debug, refactor codebase lớn. Hỗ trợ context 1 triệu tokens.

Cấu hình (chỉ cần làm 1 lần):

```
# Set environment variables (thêm vào ~/.bashrc hoặc ~/.zshrc)
export ANTHROPIC_BASE_URL="https://api-llm.x.vnshop.cloud"
export ANTHROPIC_AUTH_TOKEN="<virtual-key-được-cấp>"
```

Sử dụng:

```
claude                          # Mở Claude Code
claude --model v_glm46          # Dùng VNPAY GLM-4 on-premise
claude --model claude-sonnet-4-6 # Dùng Claude Sonnet (khi có Anthropic credits)
```

5.2 Claude Code trong VS Code

Claude Code tích hợp trực tiếp vào VS Code qua extension, hoạt động như AI pair-programmer ngay trong IDE.

Cài đặt:

1. VS Code → Extensions → Tìm **"Claude Code"** → Install
2. Mở Settings (Ctrl+,) → tìm "claude" → cấu hình:

```
// VS Code settings.json
{
  "claude-code.anthropicBaseUrl": "https://api-llm.x.vnshop.cloud",
  "claude-code.anthropicAuthToken": "<virtual-key-được-cấp>"
}
```

Hoặc cấu hình qua environment variables (tự động nhận từ terminal):

```
# Thêm vào ~/.bashrc hoặc ~/.zshrc (dùng chung với CLI)
export ANTHROPIC_BASE_URL="https://api-llm.x.vnshop.cloud"
export ANTHROPIC_AUTH_TOKEN="<virtual-key-được-cấp>"
```

Tính năng trong VS Code:

- Chat panel tích hợp bên phải IDE
- Chọn code → right-click → "Ask Claude" để hỏi về đoạn code
- Inline code suggestions và auto-complete
- Đọc toàn bộ workspace context (files, git history, terminal output)
- Chạy commands, edit files, tạo PR trực tiếp từ chat

5.3 Claude Code trong Xcode (macOS Apple Silicon)

Xcode 26.3+ tích hợp Claude Code native. Kết nối qua LiteLLM Gateway với vài bước:

Yêu cầu: macOS 26.2+, Xcode 26.3+, Mac Apple Silicon (M1/M2/M3/M4)

Bước 1: Cài Claude Code component

Xcode → Settings → Intelligence → Anthropic → Claude Agent → **Get**

Bước 2: Bypass authentication mặc định

```
defaults write com.apple.dt.Xcode IDEChatClaudeAgentAPIKeyOverride ' '
```

Bước 3: Cấu hình endpoint LiteLLM

```
mkdir -p ~/Library/Developer/Xcode/CodingAssistant/ClaudeAgentConfig
```

Tạo file `~/Library/Developer/Xcode/CodingAssistant/ClaudeAgentConfig/settings.json` :

```
{
  "env": {
    "ANTHROPIC_AUTH_TOKEN": "<virtual-key-được-cấp>",
    "ANTHROPIC_BASE_URL": "https://api-llm.x.vnshop.cloud"
  }
}
```

Bước 4: Restart Xcode

Troubleshooting: Logs tại `~/Library/Developer/Xcode/CodingAssistant/ClaudeAgentConfig/debug/`

> Ref: https://gist.github.com/zoltan-magyar/be846eb36cf5ee33c882ef5f932b754b

5.4 Antigravity & hệ thống nội bộ

Antigravity và các AI agent/service kết nối LiteLLM qua OpenAI-compatible API:

```
Base URL:  https://api-llm.x.vnshop.cloud      (public qua WAF)
API Key:   <virtual-key-được-cấp-cho-service>
```

Từ K8s pods (bypass WAF, gọi thẳng Floating IP):

```
Base URL:  http://api-llm.x.vnshop.cloud       (HTTP qua Floating IP)
hostAlias: 103.67.184.237 api-llm.x.vnshop.cloud
```

Hỗ trợ chuẩn OpenAI API (`/v1/chat/completions`) và Anthropic API (`/v1/messages`), tương thích mọi SDK/framework hiện có.

5.5 OpenAI SDK / Python / Node.js

Sử dụng bất kỳ model nào qua cùng gateway - không cần API key riêng từng provider:

```
# Environment variables
export OPENAI_BASE_URL="https://api-llm.x.vnshop.cloud/v1"
export OPENAI_API_KEY="<virtual-key-được-cấp>"
```

```
# Python
from openai import OpenAI
client = OpenAI(base_url="https://api-llm.x.vnshop.cloud/v1", api_key="<key>")
response = client.chat.completions.create(
    model="v_glm46",
    messages=[{"role": "user", "content": "Phân tích kiến trúc microservice"}]
)
```

5.6 Kết nối qua Teleport CLI (tsh v15.x.x)

Teleport CLI cho phép kết nối an toàn đến admin dashboard tại `litellm.x.vnshop.cloud` qua SSO + MFA, không cần mở port hay VPN thêm.

Yêu cầu: `tsh` CLI v14+ (proxy server v15.x.x), tài khoản VNPAY SSO

Bước 1: Login Teleport cluster

```
tsh login --proxy=teleport.x.vnshop.cloud --user=<username>@vnpay.vn
```

Browser sẽ tự mở để xác thực SSO (hoặc dùng `--auth=local` nếu dùng local account).

Kiểm tra trạng thái:

```
tsh status
```

Bước 2: Login LiteLLM app

```
tsh app login litellm
```

Lệnh này sẽ tạo client certificate trong `~/.tsh/keys/` dùng cho các request về sau.

Bước 3: Truy cập Admin Dashboard (browser)

Sau khi đã `tsh app login litellm`, mở browser và truy cập:

```
https://litellm.x.vnshop.cloud
```

Teleport tự động inject auth headers - không cần đăng nhập thêm.

Bước 4: API access qua local proxy (cho scripting/CLI)

```
# Khởi động local proxy tại cổng 4001
tsh proxy app --port=4001 litellm

# Giữ nguyên terminal trên, dùng terminal khác để gọi API
curl http://localhost:4001/health

curl http://localhost:4001/v1/models \
  -H "Authorization: Bearer <virtual-key>"

curl http://localhost:4001/v1/chat/completions \
  -H "Authorization: Bearer <virtual-key>" \
  -H "Content-Type: application/json" \
  -d '{"model":"v_glm46","messages":[{"role":"user","content":"Hello"}]}'
```

> **Lưu ý:** Local proxy (`http://localhost:4001`) không cần TLS, thích hợp cho debug và scripting. Session tsh hết hạn sau 12 giờ, cần login lại.

Logout

```
tsh app logout litellm   # Logout khỏi app cụ thể
tsh logout               # Logout khỏi toàn bộ Teleport session
```

5.7 Tổng hợp endpoints

Endpoint	Mục đích	Truy cập
`https://api-llm.x.vnshop.cloud`	API cho Claude Code, SDK, services	Public qua WAF, chỉ cần API key
`https://litellm.x.vnshop.cloud`	Dashboard UI quản trị	Qua Teleport SSO (admin only)

Endpoint	Mục đích	Truy cập
`http://localhost:4001`	API qua Teleport local proxy	`tsh proxy app --port=4001 litellm`
`http://api-llm.x.vnshop.cloud`	K8s services nội bộ	Qua Floating IP + hostAlias (bypass WAF)

6. Mô hình quản lý Team & Key

Team	Mục đích	Models	Budget/tháng
platform	GoClaw, CI/CD automation	v_glm46, Claude Sonnet	Theo dự án
dev-tools	Claude Code cho developers	All models	Theo headcount
products	Chatbot, AI features	v_glm46, Haiku	Theo sản phẩm
research	Nghiên cứu, PoC	All models	Cố định

Mỗi developer/service nhận **virtual key** riêng. Admin quản lý qua **LiteLLM Dashboard** (web UI) tại `litellm.x.vnshop.cloud/ui` - truy cập qua Teleport SSO.

7. Roadmap

Phase	Thời gian	Nội dung	Status
Phase 1	Tuần 1	Deploy LiteLLM Gateway, public endpoint qua WAF	**Done**
Phase 2	Tuần 2	Onboard 5-10 developers, setup teams & budgets	In progress
Phase 3	Tuần 3-4	Migrate GoClaw sang LiteLLM, thêm Anthropic/OpenAI credits	Planned
Phase 4	Tháng 2	Grafana cost dashboard, Guardrails config, backup	Planned

Phase	Thời gian	Nội dung	Status
Phase 5	Tháng 2-3	Onboard toàn công ty, self-service portal	Planned
Phase 6	Tháng 3+	SSO integration (VNPAY AD), device pairing, Ollama on-premise	Planned

8. Chi phí ước tính

Khoản mục	Chi phí
Hạ tầng (K8s, VNPayCloud)	Dùng chung cluster hiện tại - không phát sinh thêm
LiteLLM	Open-source, miễn phí
VNPAY GenAI (v_glm46)	Hạ tầng nội bộ sẵn có - không phát sinh thêm
API Usage (Anthropic, OpenAI)	Theo usage thực tế, kiểm soát qua budget limits
WAF/CDN + Floating IP	Chi phí minimal

ROI: Với 20 developers dùng Claude Code, tiết kiệm ước tính **3-5 giờ/dev/tuần** cho coding tasks. Kiểm soát chi phí AI tập trung thay vì phân tán qua nhiều tài khoản cá nhân.

Liên hệ: DuHD (duhd@vnpay.vn) - AI Platform Team
Public API: https://api-llm.x.vnshop.cloud
Admin Dashboard: https://litellm.x.vnshop.cloud (qua Teleport SSO)
Status: Phase 1 hoàn tất - Gateway đang chạy production, `v_glm46` tested OK