LiteLLM Gateway - Unified AI Platform cho VNPAY

> **Tài liệu nội bộ** | Ngày: 31/03/2026 | Người trình bày: DuHD - AI Platform Team
> **Đối tượng**: CTO, Tech Leaders, Engineering Managers

1. Vấn đề hiện tại

Các đội phát triển tại VNPAY đang sử dụng AI/LLM một cách phân tán:

- Mỗi developer tự quản lý API key riêng (Anthropic, OpenAI, Google...)
- Không kiểm soát được chi phí sử dụng AI trên toàn công ty
- Không có audit trail - ai dùng gì, bao nhiêu, cho mục đích gì
- Rủi ro bảo mật: API keys nằm rải rác trên máy cá nhân, Slack, .env files
- Không thể enforce policy: giới hạn model nào được dùng, budget bao nhiêu/tháng

2. Giải pháp: LiteLLM Gateway

LiteLLM là **Unified LLM Gateway** - một proxy trung tâm kết nối tất cả AI providers qua một endpoint duy nhất, chạy trên hạ tầng K8s nội bộ VNPayCloud.

```
     Consumers (gửi request)
     ========================
Claude Code    Antigravity      Hệ thống nội bộ
(Developer)    (AI Agent)       (Chatbot, QA,
                                 Automation...)
     |               |               |
     +---------------+---------------+
                     |
                     v
          +--------------------+
          |  LiteLLM Gateway   |
          |  Guardrails        |
          |  Key Management    |
          |  Cost Tracking     |
          +--------------------+
                     |
     +-------+-------+-------+-------+-------+
     |       |       |       |       |       |
     v       v       v       v       v       v
 Anthropic OpenAI  Gemini DeepSeek  Groq   Ollama
 Claude    GPT-4o  Gemini  DeepSeek Llama  (On-premise)
 Opus/     o3-pro  2.5     R1       3.3    Qwen, Llama
 Sonnet    Codex   Flash                   CodeGemma...
     ========================
     Providers (LLM backends)
```

3. Kiến trúc triển khai tại VNPayCloud

```
+-----------------------------------------------------------------+
|                      VNPayCloud K8s Cluster                     |
|                      (sdlc-go-k8s-v2)                           |
|                                                                 |
|  +--- Namespace: litellm -----------------------------------+   |
|  |                                                          |   |
|  |  +------------------+    +------------+    +---------+   |   |
|  |  | LiteLLM Gateway  |    | PostgreSQL |    |  Redis  |   |   |
|  |  | (2 replicas, HA) |--->| 16-alpine  |    | Cache   |   |   |
|  |  | Port: 4000       |    | Keys, Teams|    | Rate    |   |   |
|  |  |                  |--->| Usage Logs |    | Limit   |   |   |
|  |  | - Guardrails     |    +------------+    +---------+   |   |
|  |  | - Key Mgmt       |         5Gi PVC                    |   |
|  |  | - Cost Tracking  |                                    |   |
|  |  | - Model Router   |                                    |   |
|  |  +--------+---------+                                    |   |
|  |           |                                              |   |
|  +-----------|----------------------------------------------+   |
|              |                                                  |
|  +--- Namespace: sdlc-go-prod ---+  +--- Namespace: teleport -+ |
|  | GoClaw, Web Dashboard,       |  | Teleport Agent          | |
|  | Serena, GitNexus ...          |  | (SSO + MFA gateway)     | |
|  +------------------------------+  +-------------------------+ |
|                                                                 |
+-----------------------------------------------------------------+
       |                    |                         |
       v                    v                         v
   Anthropic API       OpenAI API              Ollama Server
   (Cloud)             (Cloud)                 (On-premise)
```

Thành phần	Chi tiết
Hạ tầng	K8s cluster `sdlc-go-k8s-v2` trên VNPayCloud (3 worker nodes, 4vCPU/8GB each)
Namespace	`litellm` - tách biệt hoàn toàn khỏi workload khác
HA	2 replicas LiteLLM + PodDisruptionBudget, zero-downtime rolling upgrade
Database	PostgreSQL 16 riêng (lưu virtual keys, teams, usage logs, model config)

Thành phần	Chi tiết
Cache	Redis (response cache, rate limiting, session state)
Ingress	NGINX Ingress Controller, TLS wildcard `*.x.vnshop.cloud`
Bảo mật	Teleport Zero Trust (SSO + MFA), SealedSecrets cho credentials, Guardrails
Monitoring	Jaeger (request tracing), Grafana (cost dashboard), Prometheus metrics
Truy cập Pilot	Qua Teleport: `litellm.x.vnshop.cloud` (không expose internet)
Truy cập Prod	Public endpoint + device pairing qua email `@vnpay.vn`

Bảo mật giai đoạn Pilot: Không expose ra internet. Mọi truy cập đều qua **Teleport** (Zero Trust Access) với xác thực SSO VNPAY. API keys provider (Anthropic, OpenAI...) lưu encrypted trong K8s SealedSecrets, developer không bao giờ thấy key gốc - chỉ nhận virtual key có rate limit và budget.

4. Lợi ích Enterprise

Chi phí & Kiểm soát

- **Cost tracking real-time**: Dashboard hiển thị chi phí theo team, dự án, cá nhân
- **Budget limits**: Set ngân sách tối đa/tháng cho mỗi team (alert khi đạt 80%)
- **Rate limiting**: Giới hạn request/phút để tránh chi phí đột biến
- **Một hóa đơn**: Thay vì mỗi dev tự mua credits riêng

Bảo mật & Compliance

- **Zero Trust (Pilot)**: Truy cập qua Teleport SSO + MFA, không expose public internet
- **Device Pairing (Prod)**: Public endpoint nhưng chỉ chấp nhận paired devices - xác thực qua email `@vnpay.vn` , key bound to device, revoke khi mất thiết bị hoặc nghỉ việc
- **Audit log**: Ghi nhận mọi request - ai, từ device nào, lúc nào, model nào, bao nhiêu tokens
- **Key rotation**: Thay đổi API key provider mà không ảnh hưởng người dùng (virtual key tách biệt khỏi provider key)
- **Data sovereignty**: Gateway chạy trên VNPayCloud, dữ liệu nhạy cảm route qua Ollama on-premise (zero data egress)
- **Guardrails**: PII auto-redaction, prompt injection blocking, data leak prevention - filter tại gateway trước khi data rời infra

On-premise Models với Ollama

LiteLLM hỗ trợ kết nối **Ollama** - chạy LLM trực tiếp trên server nội bộ VNPAY, **dữ liệu không bao giờ rời khỏi datacenter**:

```
LiteLLM Gateway
     |
     +---> Cloud: Anthropic, OpenAI, Gemini (qua internet)
     |
     +---> On-premise: Ollama Server (mạng nội bộ VNPAY)
            GPU Server / VNPayCloud VM
            ├── qwen2.5-coder:32b    (coding, 32B params)
            ├── llama3.3:70b         (general, 70B params)
            ├── codegemma:7b         (code review, nhẹ)
            ├── deepseek-r1:14b      (reasoning)
            └── gemma3:27b           (tiếng Việt tốt)
```

Cấu hình đơn giản - thêm Ollama vào `config.yaml` hoặc qua Dashboard UI:

```yaml
model_list:
  # On-premise models (Ollama) - data stays in VNPAY
  - model_name: qwen-coder-local
    litellm_params:
      model: ollama/qwen2.5-coder:32b
      api_base: http://ollama-server.vnpay.internal:11434

  - model_name: llama-local
    litellm_params:
      model: ollama/llama3.3:70b
      api_base: http://ollama-server.vnpay.internal:11434
```

Lợi ích on-premise:

	Cloud Models	Ollama On-premise
Chi phí	Pay-per-token	Một lần (GPU server) - chạy unlimited
Dữ liệu	Gửi ra internet (có Guardrails filter)	100% nội bộ - zero data egress
Latency	~500ms-2s (phụ thuộc provider)	~100-500ms (mạng LAN)

	Cloud Models	Ollama On-premise
Compliance	Phụ thuộc DPA với provider	Hoàn toàn kiểm soát
Use case	Task phức tạp cần model mạnh	Code review, dịch thuật, phân tích log, dữ liệu nhạy cảm

Hybrid routing - LiteLLM tự động route theo policy:

- Dữ liệu nhạy cảm (tài chính, PII) -> route tới **Ollama on-premise**
- Task cần model mạnh (kiến trúc, debug phức tạp) -> route tới **Claude/GPT-4o cloud**
- Task đơn giản (format code, tóm tắt) -> route tới **Ollama on-premise** (tiết kiệm chi phí)

AI Security Guardrails

LiteLLM tích hợp lớp bảo vệ **Guardrails** - kiểm soát nội dung đầu vào/đầu ra trước khi gửi tới LLM provider, đảm bảo an toàn dữ liệu doanh nghiệp:

```
Developer / App                      LLM Provider
     |                                    ^
     v                                    |
+-----------+    +----------------+    +--+--+
|  Request  |--->|  GUARDRAILS    |--->|  AI |
|           |    |                |    |Model|
|  Response |<---|  - PII Redact  |<---|     |
+-----------+    |  - Injection   |    +-----+
                 |  - Toxic Filter|
                 |  - Data Leak   |
                 |  - Custom Rule |
                 +----------------+
                 (chạy trên infra VNPAY)
```

Guardrail	Chức năng	Ví dụ
Prompt Injection Blocking	Phát hiện và chặn prompt injection attacks trong input	Chặn khi user cố gắng bypass system prompt, jailbreak model, hoặc inject lệnh độc hại qua input
PII Auto-Redaction	Tự động che/xóa thông tin cá nhân (CCCD, SĐT, STK,	`"Khách hàng Nguyễn Văn A, SĐT 0901234567"` -> `"Khách hàng [REDACTED], SĐT [REDACTED]"` - dữ liệu nhạy cảm không bao giờ rời khỏi infra VNPAY

Guardrail	Chức năng	Ví dụ
	email) trước khi gửi ra ngoài	
Toxic Response Filtering	Lọc nội dung độc hại, không phù hợp trong response từ LLM	Chặn output chứa nội dung bạo lực, phân biệt, hoặc không phù hợp với quy chuẩn doanh nghiệp
Data Leak Prevention	Ngăn rò rỉ dữ liệu nội bộ (API keys, credentials, schema DB, source code nhạy cảm)	Phát hiện và chặn khi prompt chứa connection strings, private keys, hoặc nội dung classified
Custom Policy Engine	Tạo rules riêng theo chính sách VNPAY	Ví dụ: chặn mọi request liên quan đến dữ liệu tài chính chưa public, giới hạn model nào được dùng cho dữ liệu nào, enforce tiếng Việt trong output

Điểm mấu chốt: Toàn bộ Guardrails xử lý **tại gateway trên VNPayCloud** - dữ liệu nhạy cảm được filter trước khi gửi tới Anthropic/OpenAI. Không phụ thuộc vào trust boundary của provider bên ngoài.

Cấu hình Guardrails qua `config.yaml` hoặc LiteLLM Dashboard, không cần thay đổi code phía client:

```yaml
# Ví dụ config guardrails
litellm_settings:
  guardrails:
    - prompt_injection:        # Chặn prompt injection
        callbacks: [lakera_prompt_injection]
        default_on: true
    - pii_masking:             # Che thông tin cá nhân
        callbacks: [presidio]
        default_on: true
    - content_moderation:      # Lọc nội dung độc hại
        callbacks: [openai_moderation]
        default_on: true
    - custom_vnpay_policy:     # Policy riêng VNPAY
        callbacks: [custom_guardrail]
        default_on: true
```

Linh hoạt & Tối ưu

- **Multi-provider**: Chuyển đổi giữa Anthropic/OpenAI/Gemini không cần đổi code
- **Fallback tự động**: Model A lỗi -> tự động chuyển sang Model B
- **Load balancing**: Phân tải request qua nhiều API keys cùng provider
- **Model routing**: Dùng model rẻ (Haiku) cho task đơn giản, model mạnh (Opus) cho task phức tạp

5. Hướng dẫn sử dụng

5.1 Claude Code (AI Coding Assistant)

Claude Code là CLI coding assistant của Anthropic - hỗ trợ viết code, debug, review, deploy.

```
# Bước 1: Login Teleport (một lần/ngày)
tsh login --proxy=teleport.x.vnshop.cloud --user=<tên>@vnpay.vn

# Bước 2: Mở proxy tới LiteLLM
tsh proxy app litellm -p 14000 &

# Bước 3: Cấu hình Claude Code
export ANTHROPIC_BASE_URL="http://127.0.0.1:14000"
export ANTHROPIC_AUTH_TOKEN="<virtual-key-được-cấp>"

# Bước 4: Sử dụng
claude                          # Mở Claude Code
claude --model claude-opus-4-6  # Dùng model cụ thể
```

Tính năng nổi bật: Đọc/sửa code trực tiếp, chạy tests, tạo PR, debug lỗi phức tạp, refactor codebase lớn. Hỗ trợ context 1 triệu tokens (đọc toàn bộ codebase cùng lúc).

5.2 Antigravity (AI Agent Platform)

Antigravity và các AI agent platform kết nối LiteLLM qua OpenAI-compatible API:

```
Base URL:  http://litellm.litellm.svc.cluster.local:4000  (trong K8s)
           https://litellm.x.vnshop.cloud                  (qua Teleport)
API Key:   <virtual-key-được-cấp-cho-service>
```

Hỗ trợ chuẩn OpenAI API (`/v1/chat/completions`) và Anthropic API (`/v1/messages`), tương thích mọi SDK/framework hiện có.

5.3 ChatGPT & OpenAI Models

Sử dụng GPT-4o, o3-pro qua cùng gateway - không cần API key OpenAI riêng:

```
# Từ bất kỳ OpenAI SDK/client nào
export OPENAI_BASE_URL="http://127.0.0.1:14000/v1"
export OPENAI_API_KEY="<virtual-key-được-cấp>"

# Python
from openai import OpenAI
client = OpenAI(base_url="http://127.0.0.1:14000/v1", api_key="<key>")
response = client.chat.completions.create(
    model="gpt-4o",
    messages=[{"role": "user", "content": "Phân tích kiến trúc microservice"}]
)
```

6. Mô hình quản lý Team & Key

Team	Mục đích	Models	Budget/tháng
platform	GoClaw, CI/CD automation	Claude Sonnet, Opus	Theo dự án
dev-tools	Claude Code cho developers	All models	Theo headcount
products	Chatbot, AI features	Haiku, GPT-4o	Theo sản phẩm
research	Nghiên cứu, PoC	All models	Cố định

Mỗi developer/service nhận **virtual key** riêng. Admin quản lý qua **LiteLLM Dashboard** (web UI) tại `litellm.x.vnshop.cloud/ui` - không cần SSH hay kubectl.

7. Roadmap & Mô hình truy cập theo giai đoạn

Giai đoạn Pilot (Tuần 1-4): Truy cập qua Teleport

```
Developer laptop                    VNPayCloud K8s
+-------------------+              +---------------------+
| tsh proxy app     |   Teleport   |                     |
| litellm -p 14000  |=============>| LiteLLM Gateway     |
|                   |  (encrypted) | :4000               |
| Claude Code       |              |   -> Anthropic API  |
| Antigravity       |              |   -> OpenAI API     |
+-------------------+              +---------------------+
     Mạng nội bộ                      Private network
```

- Truy cập **chỉ qua Teleport** (`tsh login + tsh proxy app`)
- Phù hợp nhóm pilot 5-10 developers đã quen Teleport
- Không cần thay đổi infra, bảo mật tối đa
- Mỗi developer cần chạy `tsh proxy app litellm -p 14000` trước khi dùng

Phase	Thời gian	Nội dung
Phase 1 (Done)	Tuần 1	Deploy LiteLLM Gateway, test Claude Code
Phase 2	Tuần 2	Onboard 5-10 developers pilot qua Teleport, setup teams & budgets
Phase 3	Tuần 3-4	Migrate GoClaw sang LiteLLM, thêm OpenAI/Gemini providers

Giai đoạn Production (Tháng 2+): Public API Gateway + Device Pairing

```
Developer laptop                        VNPayCloud K8s
+-------------------+                  +---------------------+
|                   |    HTTPS/TLS     |  Public Endpoint    |
| Claude Code       |==================>|  api.ai.vnpay.vn    |
| Antigravity       |  (direct, no VPN) |                     |
| ChatGPT client    |                  |  LiteLLM Gateway    |
+-------------------+                  |  + SSO Auth         |
        |                              |  + Device Pairing   |
        v                              +---------------------+
  Pairing flow:
  1. Dev truy cập api.ai.vnpay.vn/pair
  2. Nhập email @vnpay.vn
  3. Nhận mã xác thực qua email
  4. Nhập mã -> device được pair
  5. Nhận virtual key (bound to device)
```

Khi mở rộng toàn công ty, chuyển sang **public endpoint** để developer không cần Teleport:

Device Pairing Flow:

Bước	Hành động	Chi tiết
1	**Request pairing**	Developer truy cập portal hoặc chạy CLI setup command
2	**Email verification**	Hệ thống gửi mã OTP tới email `@vnpay.vn` của developer
3	**Xác thực mã**	Developer nhập mã OTP, device fingerprint được ghi nhận
4	**Cấp virtual key**	Key được bind với device ID + email, có thời hạn (90 ngày)
5	**Auto-renewal**	Key tự gia hạn khi device vẫn active, revoke khi device mất/đổi

Lợi ích so với Teleport-only:

- **Không cần VPN/Teleport**: Developer chỉ cần internet, không cần `tsh` CLI
- **Onboarding nhanh**: Tự đăng ký qua email, không cần admin cấp thủ công
- **Device management**: Revoke key khi nhân viên nghỉ việc hoặc mất thiết bị
- **Audit per-device**: Biết chính xác request đến từ thiết bị nào

Bảo mật production:

- Endpoint public nhưng **chỉ chấp nhận paired devices** - request không có valid key bị reject
- Virtual key **bound to device** - copy key sang máy khác sẽ không hoạt động
- Rate limiting per-device + per-team budget controls
- Guardrails (PII redaction, prompt injection blocking) vẫn active
- TLS encryption end-to-end

Phase	Thời gian	Nội dung
Phase 4	Tháng 2	Public endpoint `api.ai.vnpay.vn` , device pairing system
Phase 5	Tháng 2-3	Onboard toàn công ty, Grafana cost dashboard, self-service portal
Phase 6	Tháng 3+	SSO integration (VNPAY AD), auto-provisioning theo phòng ban

So sánh hai giai đoạn

	Pilot (Teleport)	Production (Public + Pairing)
Truy cập	`tsh proxy app` (cần Teleport CLI)	Direct HTTPS (chỉ cần internet)
Onboarding	Admin cấp key thủ công	Self-service qua email @vnpay.vn
Số user	5-10 developers	Toàn công ty (100+)
Setup time	5 phút (đã có Teleport)	2 phút (pair device qua email)
Yêu cầu	Teleport account + tsh CLI	Email @vnpay.vn + internet
Bảo mật	Zero Trust (Teleport)	Device-bound keys + TLS + Guardrails

8. Chi phí ước tính

Khoản mục	Chi phí
Hạ tầng (K8s, VNPayCloud)	Dùng chung cluster hiện tại - không phát sinh thêm
LiteLLM	Open-source, miễn phí
API Usage (Anthropic, OpenAI)	Theo usage thực tế, kiểm soát qua budget limits
Public endpoint (Phase 4)	Floating IP + domain DNS - chi phí minimal

ROI: Với 20 developers dùng Claude Code, tiết kiệm ước tính **3-5 giờ/dev/tuần** cho coding tasks. Kiểm soát chi phí AI tập trung thay vì phân tán qua nhiều tài khoản cá nhân.

Liên hệ: Du HD (duhd@vnpay.vn) - AI Platform Team
Dashboard: https://litellm.x.vnshop.cloud (qua Teleport SSO)
Status: Phase 1 hoàn tất - Gateway đang chạy production trên VNPayCloud